R2-A4-S10 GRÁFICA – RED NEURONAL (DEEP LEARNING)

Carlos Eduardo Riaño Rodriguez

Bryan Felipe Roa Alvarado

Universidad de Cundinamarca

Inteligencia Artificial Conceptos

Cundinamarca

Inteligencia Artificial

Octubre 2026

Tabla de contenido

Introducción 3

Metodología 4

Gráficas 5

Análisis comparativo 7

Aplicaciones prácticas de los resultados 8

Conclusiones 9

    Repositorio de GitHub 9

Referencias 10

Introducción

En esta práctica se trabajaron conceptos relacionados con las redes neuronales y su capacidad para aprender a partir de los datos e identificar patrones. Para ello, se utilizó un ejemplo basado en la relación entre la cantidad de fertilizante aplicada y la producción agrícola, con el propósito de entrenar y comparar modelos con diferentes números de capas ocultas. A partir de los resultados, se analizó cómo los modelos pueden estimar la producción, identificar tendencias de crecimiento y disminución, y apoyar la toma de decisiones. También se revisó la importancia de evaluar el error y comprobar que las predicciones sean confiables al trabajar con nuevos datos.

Metodología

Para realizar la práctica se utilizaron 15 pares de datos relacionados con la cantidad de fertilizante y la producción obtenida. Los datos se normalizaron para facilitar el entrenamiento de los modelos, se trabajó con TensorFlow y Keras, utilizando una red neuronal con una salida de una neurona y comparando tres configuraciones con 1, 2 y 3 capas ocultas, cada una con 16 neuronas y activación ReLU, para el entrenamiento se utilizó el optimizador Adam, con una tasa de aprendizaje de 0.01 y un total de 1000 épocas. El desempeño se evaluó mediante el error cuadrático medio (MSE).

Resultados

Los resultados obtenidos muestran que los tres modelos lograron predecir una producción aproximada de 6.80 toneladas por hectárea para una aplicación de 100 kg/ha de fertilizante, coincidiendo con el valor de referencia esperado.

Capas ocultas	Loss final (MSE normalizado)	Producción predicha 100 kg/ha (ton/ha)
1	0.000158	6.80
2	0.000040	6.80
3	0.000040	6.80

Valor de referencia esperado para 100 kg/ha: ≈ 6.8 ton/ha

Gráficas

Figura 1. Evolución del error durante el entrenamiento.

En esta gráfica se observa que los tres modelos reducen rápidamente el error durante las primeras épocas. Los modelos con dos y tres capas ocultas alcanzan un error menor en menos tiempo, mientras que el modelo de una capa tarda un poco más en estabilizarse. Esto permite ver que las tres configuraciones lograron aprender la relación entre los datos, aunque con pequeñas diferencias en su entrenamiento.

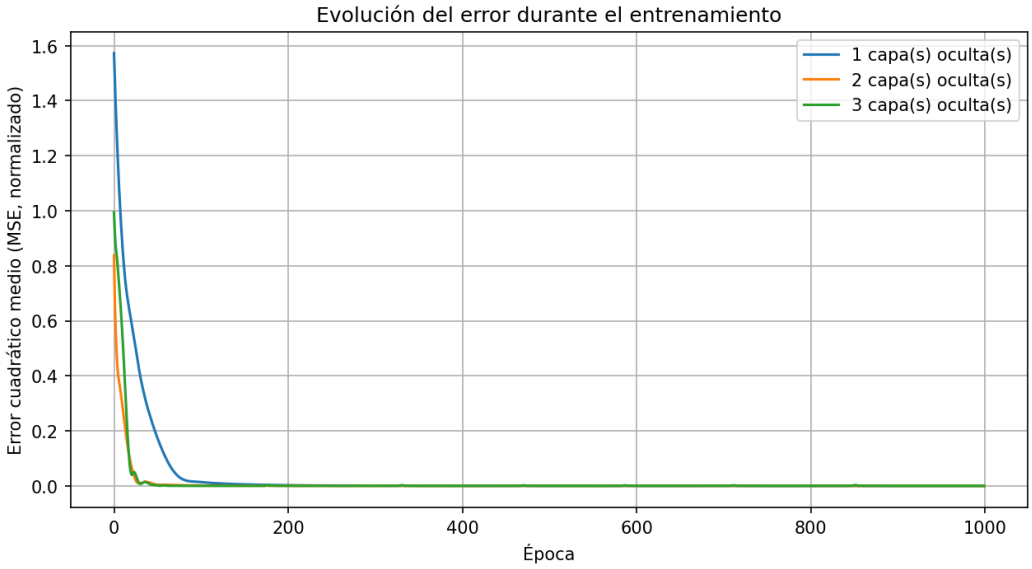


Figura 2. Ajuste de los modelos a la relación fertilizante-producción.

La gráfica muestra cómo los modelos representan la relación entre la cantidad de fertilizante aplicada y la producción agrícola. Se observa un aumento de la producción hasta alcanzar un punto máximo y, posteriormente, una disminución cuando se aplican cantidades mayores de fertilizante. Las tres configuraciones siguen una tendencia similar a la de los datos reales.

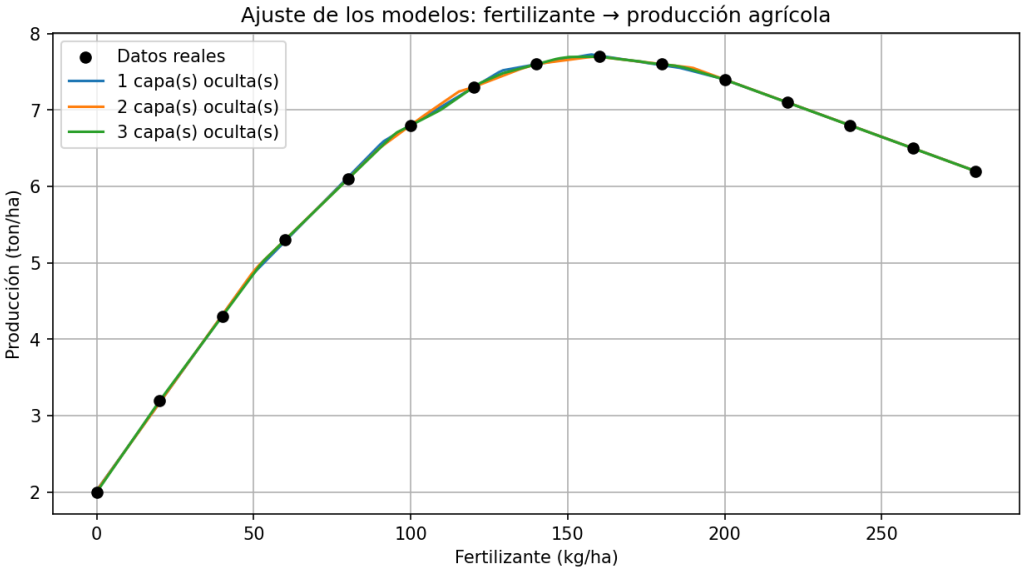


Figura 3. Arquitectura esquemática con 3 capas ocultas.

Se presenta la estructura de la red neuronal utilizada, compuesta por una neurona de entrada, tres capas ocultas de 16 neuronas cada una y una neurona de salida. Esta arquitectura permite que el modelo aprenda relaciones más complejas entre la cantidad de fertilizante y la producción.

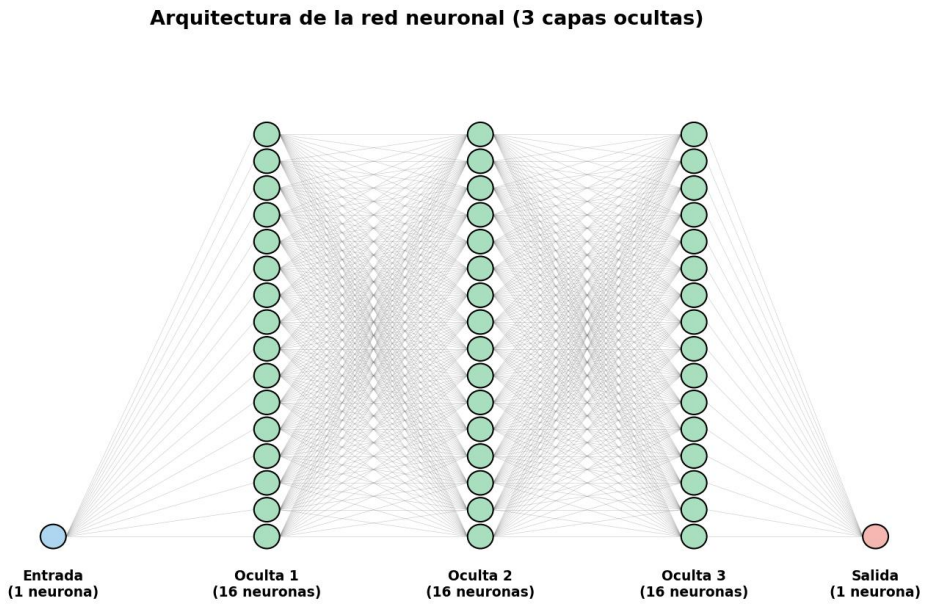
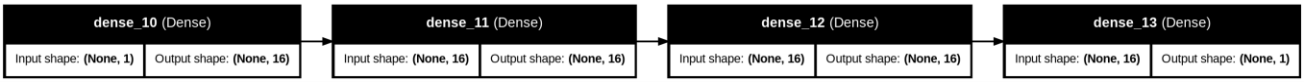


Figura 4. Diagrama de capas generado con Keras.

El diagrama permite observar la organización de las capas de la red neuronal implementada. Sirve como complemento para identificar la estructura del modelo y comprender cómo se distribuyen sus componentes durante el procesamiento de los datos.



Análisis comparativo

Modelo de una capa oculta: logra identificar la tendencia general entre la cantidad de fertilizante y la producción, pero presenta un error de entrenamiento mayor. Tiene más dificultades para representar el momento en que la producción alcanza su máximo y empieza a disminuir.

Modelo de dos capas ocultas: consigue un menor error y representa mejor el comportamiento de la curva, incluyendo el aumento de la producción y su posterior descenso. Esto permite obtener estimaciones más cercanas a los datos utilizados en la práctica.

Modelo de tres capas ocultas: obtiene un error de entrenamiento similar al modelo de dos capas y también representa la curva. Sin embargo, al trabajar con solo 15 pares de datos, existe el riesgo de que el modelo se ajuste demasiado a la información disponible y tenga dificultades para realizar predicciones con datos nuevos.

En general, los resultados muestran que aumentar el número de capas puede mejorar el ajuste, pero no garantiza que las predicciones sean mejores en todos los casos. Para este ejercicio, el modelo de dos capas parece una alternativa adecuada, aunque sería necesario probarlo con datos adicionales para confirmar su desempeño.

Aplicaciones prácticas de los resultados

Esta información se puede aprovechar de diferentes maneras en el sector agrícola:

Planificar la aplicación de fertilizantes: comparar distintas dosis para identificar cuáles podrían proporcionar una buena producción sin utilizar fertilizante en exceso.

Estimar la producción: utilizar el modelo para calcular la producción aproximada que se podría obtener con una determinada cantidad de fertilizante.

Reducir costos: comparar el costo del fertilizante con el ingreso esperado por la cosecha para buscar una alternativa económicamente conveniente.

Apoyar la toma de decisiones: identificar que una mayor cantidad de fertilizante no siempre significa una mayor producción y evaluar con más cuidado las dosis elevadas.

Por ejemplo, según los resultados del ejercicio, una aplicación de 100 kg/ha se relaciona con una producción de aproximadamente 6,8 toneladas por hectárea, si un agricultor tiene un terreno de 5 hectáreas y las condiciones son similares a las de los datos analizados, podría utilizar esa estimación como referencia inicial para una producción total de 34 toneladas. Esta cifra sería una proyección, no una garantía de cosecha, ya que también influyen factores como el clima, el suelo y el tipo de cultivo.

Conclusiones

1. La práctica permitió observar que las redes neuronales pueden aplicarse a diferentes problemas en los que se busca analizar información e identificar patrones. En este caso, se logró representar la relación entre la cantidad de fertilizante y la producción agrícola, mostrando que la producción puede aumentar o disminuir dependiendo de la cantidad aplicada.

2. El modelo de dos capas ocultas obtuvo un buen equilibrio entre el error de entrenamiento y la complejidad de la red, por eso es una alternativa interesante para continuar realizando pruebas con este conjunto de datos.

3. Los resultados pueden utilizarse como punto de partida para estimar cosechas, comparar dosis de fertilizante y apoyar decisiones relacionadas con los costos de producción. Sin embargo, es necesario validar las predicciones con más datos reales antes de utilizarlas en situaciones agrícolas.

4. Finalmente, se pudo observar que no siempre es necesario utilizar una red neuronal más compleja para obtener buenos resultados. La elección del modelo debe considerar tanto su precisión como su capacidad para responder adecuadamente ante información que no se utilizó durante el entrenamiento

Repositorio de GitHub https://github.com/carlosedu1234/R2-A4-S10-GR-FICA-RED-NEURONAL-DEEP-LEARNING-.git

Referencias

TensorFlow. (2024). Keras: The high-level API for TensorFlow. https://www.tensorflow.org/guide/keras

Van Klompenburg, T., Kassahun, A., & Catal, C. (2020). Crop yield prediction using machine learning: A systematic literature review. Computers and Electronics in Agriculture, 177, 105709. https://doi.org/10.1016/j.compag.2020.105709

Oikonomidis, A., Catal, C., & Kassahun, A. (2023). Deep learning for crop yield prediction: A systematic literature review. New Zealand Journal of Crop and Horticultural Science, 51(1), 1–26. https://doi.org/10.1080/01140671.2022.2032213

Tanaka, T. S. T., Heuvelink, G. B. M., Mieno, T., & Bullock, D. S. (2024). Can machine learning models provide accurate fertilizer recommendations? Precision Agriculture, 25, 1839–1856. https://doi.org/10.1007/s11119-024-10136-x

Barbosa, A., Trevisan, R., Hovakimyan, N., & Martin, N. F. (2020). Modeling yield response to crop management using convolutional neural networks. Computers and Electronics in Agriculture, 170, 105197. https://doi.org/10.1016/j.compag.2019.105197

Sujatha, M., & Jaidhar, C. D. (2024). Machine learning-based approaches to enhance the soil fertility—A review. Expert Systems with Applications. https://doi.org/10.1016/j.eswa.2023.122557

Olisah, C. C., Smith, L., Smith, M., Lawrence, M. O., & Ojukwu, O. (2024). Corn yield prediction model with deep neural networks for smallholder farmer decision support system. arXiv. https://arxiv.org/abs/2401.03768